

Penerapan Metode Klasifikasi Visual pada Citra Wajah Manusia untuk Analisis Hubungan Relasi Keluarga

Anyelyra Kantata
Departemen Matematika,
Universitas Indonesia
Depok, Indonesia
anyelyra.kantata21@gmail.com

I. PENDAHULUAN

A. Latar Belakang

Dengan perkembangan teknologi yang semakin maju, kemampuan untuk mengenali objek dan pola visual dari citra digital merupakan aspek yang banyak dipelajari. Dalam konteks kehidupan sehari-hari, pengenalan relasi antar wajah manusia berperan signifikan dalam bidang analisis silsilah keluarga ataupun keamanan biometrik.

Pada penelitian ini, akan dilakukan penerapan klasifikasi citra terhadap citra wajah manusia, dengan tujuan utamanya adalah mengklasifikasikan relasi antara dua individu dengan label suami-istri, ayah-anak, ibu-anak, dan saudara.

Penelitian ini akan memanfaatkan model Support Vector Machine (SVM) yang efektif dalam tugas klasifikasi citra. Oleh karena itu, proyek ini akan mengeksplorasi penerapan SVM untuk analisis hubungan visual wajah, guna mengevaluasi sejauh mana model mampu mengekstrak dan memanfaatkan fitur visual dari data untuk menghasilkan prediksi yang akurat.

B. Tujuan Penelitian

Berikut ini adalah beberapa poin tujuan pada penelitian ini:

1. Menerapkan metode klasifikasi visual berbasis Support Vector Machine (SVM) untuk mengenali relasi antar wajah manusia dalam keluarga dari pasangan citra.
2. Mengevaluasi performa model SVM dalam mengenali relasi antar wajah manusia.

II. METODOLOGI PENELITIAN

A. Support Vector Machine

Support Vector Machine (SVM) adalah algoritma klasifikasi yang berbasis pada teori pembelajaran statistik (Statistical Learning Theory) dari Vapnik. SVM bekerja dengan mencari hyperplane optimal yang memisahkan data dua kelas dengan margin maksimum. Menurut Bernhard Schölkopf, SVM memiliki keunggulan baik secara teori maupun praktik. Secara teoritis, SVM sederhana dan dapat dianalisis secara matematis.

Secara praktis, SVM mampu menangani masalah non-linear melalui teknik **kernel trick**, yang memungkinkan pemetaan data ke ruang fitur berdimensi tinggi tanpa perhitungan eksplisit. SVM juga menerapkan prinsip pengendalian kapasitas model, yang penting untuk mencegah overfitting dan meningkatkan kemampuan generalisasi. Karena keunggulan tersebut, SVM banyak digunakan dalam aplikasi nyata, termasuk pengenalan wajah dan klasifikasi hubungan antar individu.

B. Metrik Evaluasi

Evaluasi performa model dilakukan menggunakan beberapa metrik:

- **Accuracy:** Proporsi prediksi yang benar dari total data.

$$\text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN}$$

- **Precision, Recall, F1-Score:** Digunakan terutama untuk mengukur performa pada

klasifikasi dengan distribusi kelas tidak seimbang.

- **Precision** mengukur seberapa banyak hasil yang diprediksi positif benar-benar positif.
- **Recall** mengukur seberapa banyak data positif yang berhasil diklasifikasikan dengan benar.
- **F1-Score** adalah rata-rata harmonis dari precision dan recall.

III. IMPELEMENTASI

A. Data

Data yang digunakan pada objek wajah manusia ini merupakan foto dari beberapa keluarga tokoh publik yang secara manual dibentuk oleh penulis melalui sumber-sumber dari internet. Data ini juga disertai dengan data label relasi untuk setiap pasangan wajah pada setiap kelompok keluarga. Berikut adalah head dan tail dari data label yang diperoleh dan siap dianalisis.

No	family_id	person1	person2	relationship
1	hemsworth_family	luke	liam	saudara
2	hemsworth_family	luke	chris	saudara
3	hemsworth_family	liam	chris	saudara
4	reynolds_family	ryan	blake	suami-istri
5	beckham_family	david	victoria	suami-istri
⋮	⋮	⋮	⋮	⋮
80	ganjar_family	ganjar	alam	ayah-anak
81	ganjar_family	siti	alam	ibu-anak

B. Ekstraksi Fitur

Untuk mengekstraksi fitur dari data citra wajah, digunakan model CNN **MobileNetV2** dengan bobot **imagenet**. Layer atas dari model tersebut (**include_top**) dihilangkan dan digantikan dengan **GlobalAveragePooling2D** untuk menghasilkan fitur berupa vektor dengan dimensi tetap.

```
def load_and_resize_image(path, size=IMG_SIZE):
    img = cv2.imread(path)
    if img is None:
        return None
    img = cv2.cvtColor(img, cv2.COLOR_BGR2RGB)
    img = cv2.resize(img, (size, size))
    return img

base_model = MobileNetV2(weights='imagenet', include_top=False,
input_shape=(IMG_SIZE, IMG_SIZE, 3))
model_cnn = tf.keras.Sequential([
    base_model,
    tf.keras.layers.GlobalAveragePooling2D()
])
model_cnn.trainable = False
```

Lalu, fitur dari setiap pasangan gambar digabungkan secara horizontal (**concatenate**) untuk membentuk representasi pasangan.

```
combined_feat = np.concatenate([feat1, feat2])
X.append(combined_feat)
y.append(row['relationship'])
```

C. Preprocessing Data

Seluruh citra pada dataset diubah ukurannya menjadi 160×160 piksel. Data yang telah diubah ukurannya ini kemudian diproses menggunakan **preprocess_input** dari TensorFlow. Pasangan gambar yang gagal diproses atau tidak ditemukan akan dikeluarkan dari dataset.

```
img1_pre = preprocess_input(np.expand_dims(img1, axis=0))
img2_pre = preprocess_input(np.expand_dims(img2, axis=0))
```

D. Pembagian Data

Data dibagi dengan rasion 80:20 menggunakan **train_test_split**, juga menggunakan stratifikasi berdasarkan label, sehingga distribusi kelas di data *training* dan data *testing* seimbang.

```
X_train, X_test, y_train, y_test, train_idx, test_idx =
train_test_split(
    X, y_encoded, np.arange(len(y_encoded)),
    test_size=0.2, random_state=42, stratify=y_encoded)
```

Selain itu, label dikodekan menjadi bilangan bulat dengan menggunakan **LabelEncoder**.

```
le = LabelEncoder()
```

E. Model Training

Support Vector Machine dipilih karena mampu menangani *dataset* berdimensi tinggi dan *robust* terhadap *overfitting*. Model ini juga dipilih karena *dataset* dengan jumlah yang relatif terbatas, tetapi dengan hasil ekstraksi fitur CNN yang cukup kompleks. Pada *training* model ini digunakan kernel linear dipilih sebagai pendekatan awal karena dimensi fitur cukup tinggi dan model cenderung lebih cepat dilatih.

```
model = SVC(kernel='linear', probability=True)
```

F. Model Evaluation

Untuk evaluasi model, digunakan metrik evaluasi, seperti Precision, Recall, dan F1-score untuk masing-masing kelas hubungan.

Accuracy: 0.6875

Classification report:



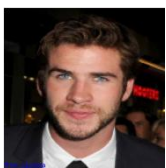
	precision	recall	f1-score	support
ayah-anak	0.50	0.67	0.57	3
ibu-anak	0.75	0.75	0.75	4
saudara	0.83	0.83	0.83	6
suami-istri	0.50	0.33	0.40	3
accuracy			0.69	16
macro avg	0.65	0.65	0.64	16
weighted avg	0.69	0.69	0.68	16



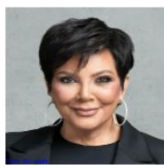




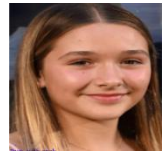

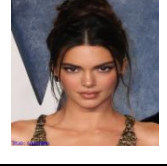
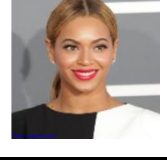
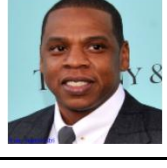

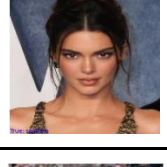
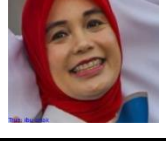

Interpretasi dari hasil metrik evaluasi:

- Kelas 'ibu-anak' dan 'saudara' memiliki performa terbaik dengan F1-score masing-masing adalah 0.75 dan 0.83. Hal ini dapat disebabkan oleh konsistensi fitur visual yang cukup kuat, seperti kemiripan wajah anak dengan ibu atau kemiripan wajah antara saudara kandung.
- Kelas 'suami-istri' memiliki performa paling rendah. Hal ini cukup wajar karena model mungkin sulit mengenali kemiripan visual karena umumnya tidak memiliki kemiripan genetik tertentu.
- Hasil akurasi yang belum cukup maksimal juga dapat disebabkan ketidakseimbangan jumlah data pada kelas dan *dataset* yang cukup kecil.

G. Hasil Prediksi

Berikut ini adalah hasil prediksi model pada data *testing* untuk 10 pasangan gambar pertama:

No	Gambar 1	Gambar 2	Hasil
1			True: saudara Pred: saudara
2			True: saudara Pred: saudara

3			True: saudara Pred: ayah-anak
4			True: ibu-anak Pred: ibu-anak
5			True: ibu-anak Pred: ibu-anak
6			True: ayah-anak Pred: ayah-anak
7			True: saudara Pred: saudara
8			True: suami-istri Pred: ibu-anak
9			True: saudara Pred: saudara
10			True: ibu-anak Pred: ayah-anak

IV. KESIMPULAN

Dengan akurasi bernilai 0.6875 dapat dikatakan bahwa model SVM cukup baik dalam menangani analisis relasi keluarga berdasarkan citra visual. Namun, hasil ini belum maksimal dalam memprediksi hubungan antara pasangan gambar. Kekurangan ini dapat disebabkan oleh data yang tidak seimbang dan ukuran *dataset* yang cukup kecil.

V. REFERENSI

Powers, D. M. (2011). *Evaluation: From precision, recall and F-measure to ROC, informedness, markedness and correlation*. Journal of Machine Learning Technologies, 2(1), 37–63.

Hearst, M. A., Dumais, S. T., Osuna, E., Platt, J., & Scholkopf, B. (1998). Support vector machines. *IEEE Intelligent Systems and their applications*, 13(4), 18-28.

Wu, J. (2017). Introduction to convolutional neural networks. *National Key Lab for Novel Software Technology. Nanjing University. China*, 5(23), 495.